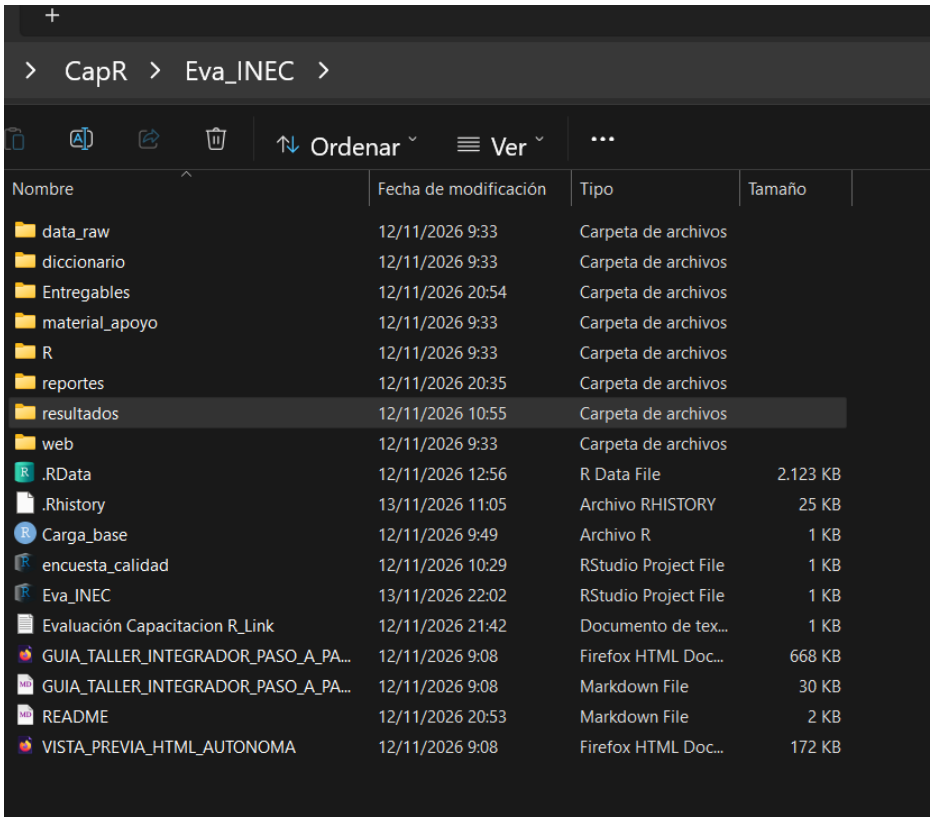
Taller integrador de calidad de datos

Integrantes del grupo:

- Erika Cerda
- María del Carmen Moran
- Nathaly Veloz

Respuesta a preguntas planteadas en el paso a paso para generar el reporte de calidad

Evidencia E0: Captura de rutas



¿Por qué read_csv() no debe decidir automáticamente todos los tipos de datos?

Dejar que read_csv() infiera tipos automáticamente es riesgoso porque puede alterar identificadores con ceros a la izquierda o convertir textos no estándar (como "USD 410" o "950,50") en valores faltantes NA sin advertencia. Para evitar distorsionar la fuente original, conviene aplicar una importación conservadora mediante col_character() para leer primero todo como texto. Así aseguramos que la información se conserve intacta para auditarla antes de cualquier transformación

Evidencia E1: resultados/tablas/01_diagnostico_variables.csv y resultados/01_datos.rds. Abra el CSV y explique cuáles variables requieren prioridad de revisión.

En 01_diagnostico_variables.csv, las variables prioritarias por ausencias son ingreso_mensual_usd (24 ausencias, 1,00%), edad (12, 0,50%), nivel_educacion (10, 0,42%) e id_hogar (5, 0,21%). Asimismo, id_persona revela duplicados al registrar 2.382 valores distintos en 2.400 filas. Adicionalmente, al contrastar con la base completa y sus catálogos, se requiere revisar zona y provincia por contar con más categorías distintas de las esperadas (4 y 7 respectivamente), así como inconsistencias de consistencia en horas_trabajo_semana

Evidencia E2: resultados/tablas/02_alertas_variables.csv; seleccionen tres reglas, identifiquen una fila y expliquen si es error confirmado, advertencia o ausencia.

De 02_alertas_variables.csv:

- Regla V07 (nivel_educacion = "SUPERIOR"): Es una advertencia de formato, refleja una variante en mayúsculas normalizable a "Superior", sin ser error irrecuperable ni ausencia.
- Regla V04 (ingreso_mensual_usd = "950,50"): Es una advertencia de formato por uso de coma decimal, rescatable mediante limpieza.
- Regla V02 (edad = -2): Es una advertencia por valor fuera de rango didáctico, que exige auditoría metodológica previa antes de ser modificada o imputada.

Evidencia E3: 03_huerfanos.csv, 03_alertas_integridad.csv y explicación de un duplicado y una referencia sin correspondencia.

Un duplicado (regla I01 en 03_alertas_integridad.csv) ocurre cuando la clave id_persona (P20261000606) se repite en el mismo período, señalando filas repetidas o asignación errónea de ID. Una referencia sin correspondencia o llave huérfana (03_huerfanos.csv) sucede cuando id_hogar tiene un código inexistente en la tabla maestra (H9999999999). No debe borrarse a ciegas, pues suele responder a un error de digitación; eliminar el registro descartaría datos socioeconómicos válidos y sesgaría los denominadores muestrales.

Evidencia E4: resultados/tablas/04_bitacora_propuesta.csv y resultados/04_escenarios.rds. Compare tres normalizaciones y un caso que se mantiene pendiente de revisión.

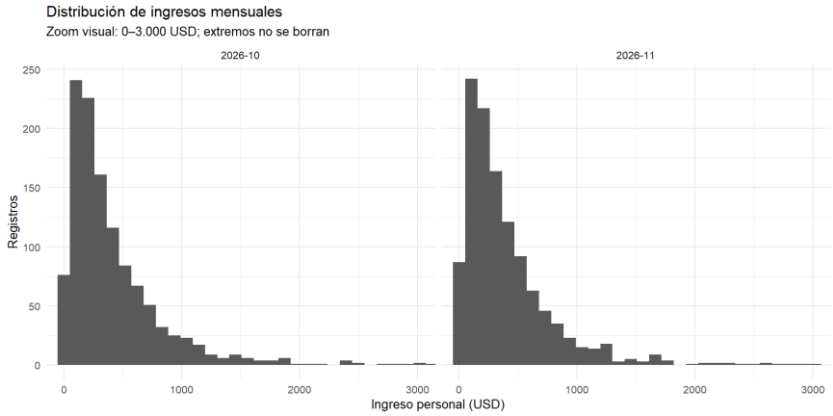
En 04_bitacora_propuesta.csv se registran normalizaciones de etiquetas (regla NORMALIZACION_ETIQUETA): estandarizar provincias ("PICHINCHA" a "Pichincha"), ajustar zonas ("URBANA" a "Urbana") y homogeneizar niveles educativos ("SUPERIOR" a "Superior"). Por otro lado, los 28 registros en la bitácora figuran en estado PENDIENTE DE AUTORIZACION. Esto ocurre porque el proceso técnico genera la propuesta de depuración, pero no puede alterar la base oficial sin la validación y autorización previa del área metodológica responsable.

Evidencia E5: 05_indicadores.csv, 05_indicadores_periodo.csv, 05_resumen_ingresos.csv, 05_educacion_zona.csv, 05_pobreza_zona.csv, 05_resumen_alertas.csv. Explique una diferencia en puntos porcentuales y compruebe el numerador/denominador de un indicador.

En 05_indicadores.csv, el indicador de **Validez** pasa de 99,57% en el escenario Original (numerador 11903/ denominador 11954) a 99,69% en el escenario Propuesto (numerador 11917/ denominador 11954). Esta diferencia de +0,12 puntos porcentuales refleja la corrección exitosa de 14 evaluaciones aplicables. Los demás indicadores permanecen idénticos entre escenarios: Completitud (14354/14400 = 99,68%), Unicidad (2364/2400 = 98,50%) y Consistencia (4762/4794 = 99,33%).

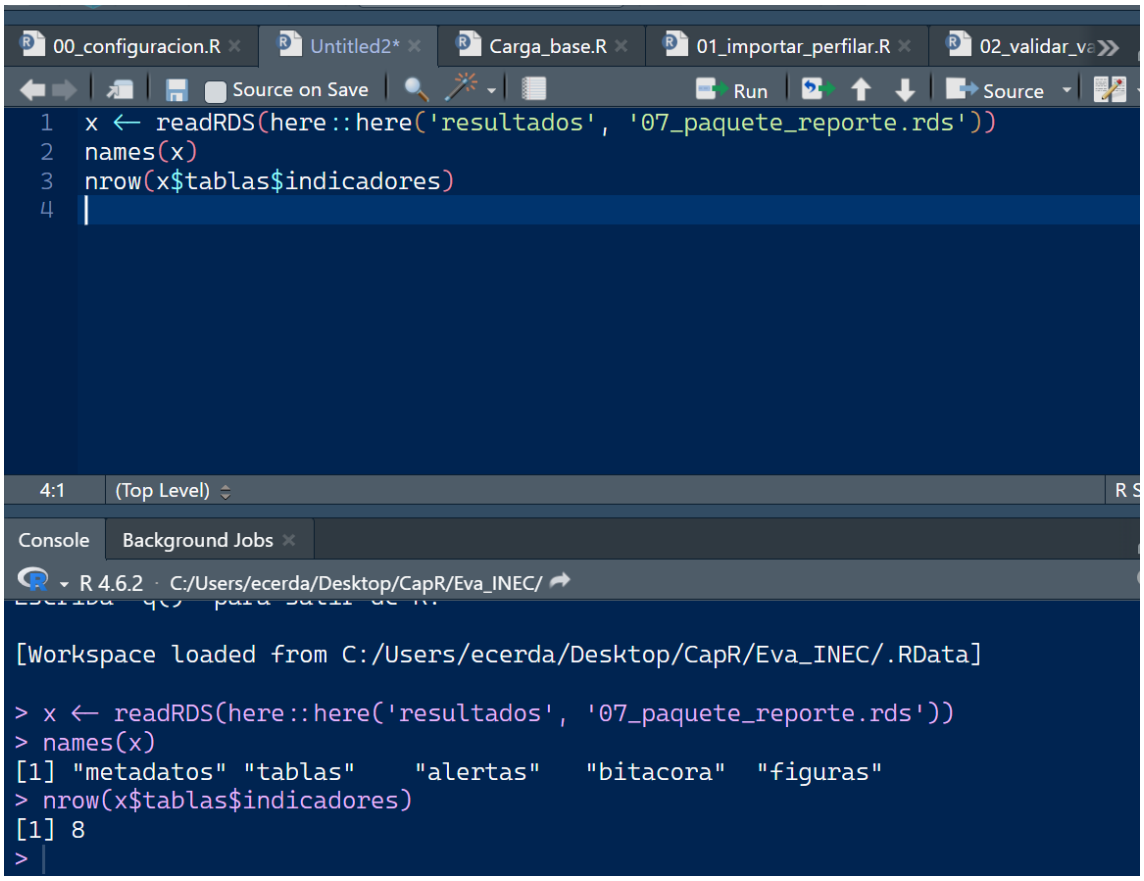
Evidencia E6: cinco PNG en resultados/figuras/. Seleccione uno y explique el denominador, una conclusión que sí se justifica y una conclusión que sería indebida.

En el histograma de ingresos (06_ingresos.png):



- **Denominador:** Personas con ingresos numéricos válidos mayores o iguales a cero.
- **Conclusión justificada:** Existe un sesgo a la derecha donde la media (USD 426,47 en octubre urbano) supera a la mediana (USD 279,36) por la presencia de ingresos altos.
- **Conclusión indebida:** Afirmar que se eliminaron ingresos superiores a USD 3000; la gráfica únicamente realiza un acercamiento visual a dicho rango sin borrar datos de la base.

Evidencia E7 (obligatoria): archivo físico resultados/07_paquete_reporte.rds, captura de names(x) y comprobación de lectura.



A continuación, se presentan las preguntas planteadas sobre el ejercicio realizado, las cuales se encuentran registradas en el reporte del taller:

¿Por qué un dataset con pocas ausencias todavía puede tener problemas de validez, unicidad e integridad?

Que no existan casillas vacías no garantiza datos correctos. Un registro presente puede ser inválido por errores de formato o rango, perder unicidad al estar duplicado, o carecer de integridad si contradice a otras variables o tablas relacionales. Estar lleno no implica estar libre de inconsistencias.

¿Cómo distinguirá una fila repetida de dos personas con un mismo identificador?

Una fila repetida es un duplicado idéntico en todos sus campos. En cambio, si dos personas comparten identificador, los registros tienen el mismo ID pero sus datos socioeconómicos son distintos, revelando un problema de unicidad que exige auditoría sobre el origen del código.

¿Qué significa un id_hogar sin correspondencia, y por qué no debemos eliminarlo sin investigación?

Indica que una persona apunta a un hogar inexistente en la base. No debe borrarse a ciegas porque podría ser un simple error tipográfico al digitar el ID. Eliminarlo sin investigar descartaría información útil del encuestado y alteraría los denominadores de la muestra.

¿Qué diferencia existe entre media y mediana ante un ingreso extremo alto?

Los ingresos muy altos inflan la media, arrastrándola hacia arriba. La mediana, al situarse en el centro de los datos ordenados, resiste esos valores extremos y refleja con mayor fidelidad cuál es el ingreso típico que percibe la mayoría de la población.

¿Cuál es la diferencia entre corrección propuesta y corrección aprobada?

La propuesta es una sugerencia técnica de depuración aún no autorizada. La aprobada es aquella validada e incorporada formalmente a la base. Mientras permanezca como propuesta, no modifica la base oficial ni altera los resultados definitivos del informe.

¿Qué indicador mejoró entre escenario original y propuesta? ¿Es correcto afirmar que mejoró la estadística oficial?

Mejoró únicamente la validez (del 99,57% al 99,69%), recuperando 14 registros válidos. No es correcto afirmar que mejoró la estadística oficial, ya que se trata de propuestas no autorizadas dentro de una simulación académica sintética.

¿Por qué saveRDS() es necesario antes de elaborar el reporte Quarto?

Permite congelar la base procesada en un archivo liviano. Así evitas repetir cálculos pesados cada vez que renderizas el documento en Quarto, garantizando rapidez, orden y reproducibilidad total en la generación del informe final.

¿Qué diferencia práctica existe entre generar un documento HTML y generar un sitio web de dos páginas?

El HTML crea un archivo único y continuo.El sitio web de dos páginas organiza el contenido de forma modular en pestañas independientes, permitiendo separar, por ejemplo, el resumen ejecutivo de los anexos técnicos para facilitar la lectura.

¿Por qué los resultados desbalanceados no deben extrapolarse a Ecuador?

La muestra proviene de un ejercicio sintético diseñado con un desbalance intencional. Al carecer de representatividad probabilística y de factores de expansión reales, cualquier intento de extrapolar los hallazgos al país generaría conclusiones falsas.

¿Por qué la variable pobreza_didactica no equivale a pobreza monetaria oficial?

La pobreza_didactica usa un umbral ilustrativo de USD 185 por persona, fijado solo para este taller. No aplica la metodología del INEC ni sus canastas oficiales, por lo que su función es puramente didáctica.